El Índice de Dependencia de IA (IDA): cuantificar la dotación mínima de continuidad en organizaciones dependientes de inteligencia artificial

César Riat

All AIdeas SAS, Ciudad Autónoma de Buenos Aires, Argentina
ORCID 0009-0000-6851-5295 · criat@allaideas.com

Resumen

Problema: Las organizaciones que adoptan inteligencia artificial calculan a cuánta gente pueden reducir. No encontré un marco publicado que cuantifique cuánta debe conservar para seguir operando si el proveedor deja de estar disponible. El 12 de junio de 2026 una orden de control de exportaciones de Estados Unidos obligó a un proveedor de frontera a suspender dos de sus modelos más avanzados para todo ciudadano extranjero; sin manera de verificar la nacionalidad en tiempo real, los apagó para todos sus clientes del mundo hasta el 30 de junio [6]. La interrupción se originó en una decisión política, no en la infraestructura. **Vacío:** Los marcos de resiliencia prescriben mapear dependencias y tener contingencias sin dimensionarlas. El AI Resilience Framework [1] deja sin desarrollar un puntaje cuantitativo de sustituibilidad; acá se desarrolla en términos de dotación. **Método:** Este trabajo propone el Índice de Dependencia de IA (IDA), un modelo determinístico construido sobre seis datos operativos, un piso de continuidad declarado, el gasto de IA y tres parámetros de proyecto. Devuelve la dotación a conservar, un ahorro ajustado por riesgo, una inversión máxima defendible y un índice de exposición de 0 a 100. **Hallazgos:** Pasado el piso de continuidad, automatizar más aumenta la factura de IA sin liberar a nadie: el ahorro cae mientras la dependencia sube. Si la IA se paga como capacidad fija y no por uso —por ejemplo, equipos propios comprados para correr los modelos—, el ahorro se aplana en lugar de caer, pero la dependencia sigue subiendo: automatizar de más la compra a cambio de nada. El mejor nivel de automatización efectiva resulta estar exactamente donde el piso de continuidad empieza a mandar, y su posición depende solo de la dotación y de ese piso. **Robustez:** Los coeficientes de fragilidad los fijó el criterio del autor, no una medición. Se repitió el cálculo 20.000 veces moviendo cada uno al azar, hasta un 50 por ciento arriba o abajo. **Ese punto donde conviene dejar de automatizar no se movió**, ni tampoco el orden entre arquitecturas. Lo que sí cambió fue el veredicto sobre un proyecto concreto: por eso el modelo informa el umbral en el que ese veredicto se invierte, en lugar de decir solo si conviene invertir o no. **Disponibilidad:** El modelo, sus fórmulas, una implementación ejecutable, una batería de 25 casos de borde y el análisis de robustez de la Sección 4.5 se publican bajo licencia MIT y quedan depositados con un identificador permanente [2]. Se ejecuta en **modelo-ida.web.app**.

Palabras clave: resiliencia operativa; continuidad del negocio; dependencia de IA; concentración de proveedores; planificación de dotación; sistemas de soporte a la decisión.

1. Introducción

Todo caso de negocio de automatización responde la misma pregunta: de cuánta gente vamos a poder prescindir. La pregunta es vieja, la aritmética es conocida, y la respuesta alimenta un cálculo de retorno que cualquier directorio sabe leer.

Hay una segunda pregunta que ese mismo caso de negocio no hace. Si el trabajo automatizado ahora depende de un proveedor externo, y ese proveedor deja de estar disponible, ¿cuánta gente necesita la organización para seguir operando en condiciones mínimas? No es el primer número con el signo cambiado. Es otra cantidad, gobernada por otra restricción, y en la práctica actual sencillamente no se calcula.

Mientras el riesgo era hipotético, no calcular esa segunda cantidad no tenía consecuencias visibles. Dos hechos de 2026 lo cambiaron.

Primero, el precio. Lo que una organización paga por unidad de inferencia no está atado a una estructura de costos que el comprador pueda inspeccionar ni prever. Lo fija unilateralmente un proveedor cuyo propio modelo de negocio todavía no está resuelto, lo que significa que el costo operativo de un proceso automatizado puede moverse por razones enteramente ajenas al adoptante y sin relación con su propio

consumo.

Segundo, la disponibilidad, y este ya no es hipotético. El 12 de junio de 2026 el Departamento de Comercio de Estados Unidos emitió a Anthropic una directiva de control de exportaciones que la obligaba a suspender el acceso a dos de sus modelos más avanzados, Claude Fable 5 y Claude Mythos 5, por parte de cualquier ciudadano extranjero, estuviera dentro o fuera de Estados Unidos [6]. Sin manera de verificar la nacionalidad de cada usuario en tiempo real, el proveedor apagó ambos modelos para todos sus clientes del mundo [7]. Los controles se levantaron el 30 de junio, casi tres semanas después, y el acceso se restableció por etapas [8]. No falló ninguna infraestructura. No se incumplió ningún acuerdo de nivel de servicio en el sentido habitual. Una infraestructura multi-nube no habría bastado por sí sola para sortear la restricción, porque la restricción no era técnica. Los demás modelos del proveedor siguieron disponibles, pero eso no equivale a tener una contingencia: conmutar de modelo no es automático. Exige monitoreo que dé el aviso, alguien que toque el código allí donde el identificador del modelo está fijo, y que la conmutación esté ensayada de antemano. Si falta cualquiera de las tres, la interrupción sucede igual y dura lo que tarde la gente en resolverla — o sea que vuelve a medirse en horas de capacidad humana. La Sección 6 vuelve sobre esa distinción, que el modelo actual todavía no cobra.

Una organización que hubiera automatizado un proceso crítico sobre ese proveedor tuvo, durante esas tres semanas, exactamente tanta capacidad operativa como gente había conservado que todavía supiera hacer el trabajo a mano. Muy pocas conocían ese número de antemano.

Procedencia: El modelo condensa alrededor de una década de práctica de consultoría en adopción de inteligencia artificial y automatización, en sectores regulados y de operación crítica, durante la cual su formulación fue revisada una y otra vez contra intervenciones que aquí no pueden identificarse por confidencialidad con los clientes. Esa historia es la razón por la que el modelo pide seis datos operativos y no sesenta: se eliminó todo dato que un responsable no pudiera contestar de memoria en una reunión. Es también, necesariamente, un límite sobre la evidencia que este trabajo puede ofrecer: esas intervenciones moldearon el modelo, pero no se pueden mostrar, así que este trabajo no las presenta como evidencia. El caso publicado en la Sección 4 es construido y no observado. La validación empírica independiente queda por lo tanto abierta, y la Sección 6 indica qué la cerraría.

Contribución: Este trabajo propone el Índice de Dependencia de IA (IDA), un modelo determinístico que calcula la dotación mínima que una organización debe conservar para mantener la continuidad, el ahorro que queda una vez incorporadas esa restricción y la fragilidad de la arquitectura, la inversión máxima que semejante proyecto puede justificar, y un índice acotado de exposición operativa. El modelo es deliberadamente pequeño: su núcleo operativo son seis datos que cualquier responsable de operaciones ya posee, no requiere conjunto de datos ni entrenamiento, y se publica completo para que sus resultados puedan reproducirse o refutarse.

2. Trabajo relacionado y el vacío

Tres líneas de trabajo ya existentes tocan este problema: las normas de gobernanza, la continuidad del negocio y la literatura reciente sobre resiliencia de IA. Ninguna de las tres devuelve una cantidad de gente.

Normas de gobernanza: La ISO/IEC 42001 [3] establece requisitos para un sistema de gestión de inteligencia artificial, incluidos la evaluación y el tratamiento de riesgos. El reglamento europeo de resiliencia operativa digital (DORA) [5] obliga a las entidades financieras a mapear sus dependencias tecnológicas y a probar su resiliencia frente a escenarios severos pero plausibles. Ambos son prescriptivos sobre el proceso y silenciosos sobre la magnitud: exigen que exista un plan de contingencia, no que esté dimensionado.

Evidencia regulatoria sobre concentración: La dependencia que este trabajo dimensiona ya está siendo medida por los supervisores. En la encuesta de 2024 del Banco de Inglaterra y la Financial Conduct Authority sobre los servicios financieros británicos, un tercio de los casos de uso de IA eran implementaciones de terceros, contra el 17 por ciento dos años antes, y los tres principales proveedores concentraban el 73, el 44 y el 33 por ciento de todos los proveedores informados de nube, modelo y datos respectivamente [9]. La

dirección importa más que los niveles. Ese 44 por ciento mide **concentración**: qué porción de todos los proveedores de modelo que las firmas declararon usar se reparte entre solo tres empresas. Comparado con la misma encuesta de 2022, esa porción **subió del 18 al 44 por ciento** en la capa de modelo, mientras que en la nube la porción de los tres principales proveedores **bajó**. No quiere decir que se use menos la nube: quiere decir que ese mercado se repartió entre más empresas, mientras que el de modelos se concentró. La concentración está migrando de la infraestructura al modelo. El Comité de Política Financiera planteó desde entonces, como escenario de estabilidad financiera, que allí donde las funciones de atención al cliente pasaron a depender fuertemente de modelos de IA provistos por terceros, una caída generalizada de uno o varios modelos clave podría dejar a muchas firmas sin poder entregar servicios vitales como los pagos con plazos críticos [10]. Ese escenario se publicó en abril de 2025, catorce meses antes del episodio de la Sección 1.

La respuesta de política fue institucional y no cuantitativa. La Financial Services and Markets Act de 2023 estableció un régimen para terceros críticos, en respuesta a la conclusión de 2021 de que la concentración en la provisión de servicios a las firmas británicas podía elevar el riesgo para la estabilidad financiera sin medidas adicionales; el Banco, la Prudential Regulation Authority y la Financial Conduct Authority publicaron las reglas conjuntas de ese régimen en noviembre de 2024 [10][11]. En enero de 2026 el comité del Tesoro de la Cámara de los Comunes recomendó que el Tesoro designara a los grandes proveedores de IA y de nube como terceros críticos antes de fin de 2026 [12]. Ninguno de esos instrumentos dice cuánta gente debe conservar una firma para operar a través del escenario que el propio comité describe. Esa es la cantidad que este trabajo calcula.

Continuidad del negocio: La disciplina que se ocupa de que una organización siga funcionando cuando algo falla ya aporta el aparato conceptual para un nivel operativo mínimo, sobre todo a través del análisis de impacto en el negocio y de la noción de objetivo mínimo de continuidad [4]. Lo que no aporta es una manera de derivar ese nivel a partir de la estructura específica de una dependencia de IA, donde el recurso sustituto es trabajo humano que la propia decisión de automatizar está en proceso de retirar.

Literatura reciente sobre resiliencia de IA: El trabajo publicado más cercano es el AI Resilience Framework [1], que sostiene que una gobernanza centrada en la confiabilidad deja insuficientemente cubierta una obligación de resiliencia, y propone mapeo de dependencias, clasificación por criticidad y sustituibilidad, protocolos de contingencia y gestión de la concentración de proveedores. Ese marco identifica explícitamente un puntaje cuantitativo de sustituibilidad como una extensión natural que permitiría calibrar los umbrales en lugar de afirmarlos, y no la desarrolla. El presente trabajo toma esa extensión y expresa la sustituibilidad en la única unidad en la que un protocolo de contingencia puede efectivamente ejecutarse: personas que sepan hacer el trabajo.

Existe trabajo de índices adyacente que responde otra pregunta. Los índices de transformación por inteligencia artificial a nivel de firma y de industria miden oportunidad, riesgo de disrupción y creación de valor [13]; describen cuánto puede ganar una organización, no cuánta capacidad operativa conservaría si la tecnología dejara de estar disponible.

Un resultado reciente sí llega a una conclusión de sobreautomatización, por un camino enteramente distinto. Falk y Tsoukalas [14] muestran, en un modelo competitivo basado en tareas, que una externalidad de demanda lleva a firmas racionales a **automatizar por encima del nivel colectivamente óptimo**, porque cada firma captura el ahorro completo de reemplazar a un trabajador y soporta solo una parte de la caída de demanda resultante. El presente modelo llega a un resultado de sobreautomatización a otra escala y sin necesidad de externalidad alguna: **pasado el piso de continuidad, una sola firma automatiza por encima de su propio óptimo**, por razones internas a sus propias cuentas. Los dos son complementarios, uno macroeconómico y otro operativo, y ambos contradicen la premisa de que la automatización máxima es la automatización óptima.

La prescripción de esas tres líneas es cualitativa. La decisión que tiene que firmar un director de operaciones, un responsable de continuidad o un comité de riesgos es cuantitativa: cuántas personas se conservan. Ese número es el que falta.

3. El modelo

Un mismo caso recorre esta sección, de modo que cada cantidad aparece con su valor y no solo con su definición. **Una organización automatiza su centro de atención al cliente.** Son diez personas que contestan **correos, llamadas y mensajes de WhatsApp**, con una nómina mensual de 16.000, y cada una trabaja 160 horas por mes. El 60 por ciento del trabajo podría hacerlo el sistema, y en producción rinde al 80 por ciento. De ese trabajo automatizable, un quinto **no se delega**: en parte porque una norma exige que lo autorice una persona habilitada, y en parte porque la propia organización decide no delegarlo — por ejemplo, que la IA clasifique el reclamo pero que una persona conteste cuando el cliente amenaza con acciones legales. Y hay 640 horas de trabajo por mes que deben cubrirse pase lo que pase, que no son las de una persona sino las de todo el equipo sumadas. La Sección 4.1 retoma el mismo caso con todas las cifras en una tabla. No se nombra ningún sector porque no se supone ninguno: el modelo le hace las mismas preguntas a un banco, a un hospital o a un operador logístico.

Antes de las fórmulas conviene saber que el modelo tiene dos partes, que se apoyan en cosas distintas y por eso se defienden por separado. La primera **cuenta horas**: cuánto trabajo pasa a hacer la IA, cuánto hay que poder cubrir sin ella y cuánto trabaja una persona. De esa cuenta salen cuánta gente conservar y a partir de qué nivel automatizar más ya no libera a nadie. No usa ningún número elegido por el autor, así que vale para cualquiera que acepte cómo se cuentan las horas. Se la llama parte **estructural**.

La segunda **le pone precio al riesgo**: cuánto más cara hay que considerar la IA según lo frágil que sea la arquitectura, y con eso cuánto se ahorra, cuánto se puede invertir y cuán expuesta queda la organización. Ese precio sale de primas fijadas por criterio experto, y por eso sus valores absolutos son tan discutibles como esas primas. Se la llama parte **heurística**.

Las dos son independientes en un sentido preciso: la heurística usa los resultados de la estructural, pero la estructural no usa nada de la heurística. Por eso quien rechace todas las primas puede descartar la parte heurística y quedarse con la estructural intacta. La Tabla 1 resume la diferencia; las variables se presentan una por una a partir de la Sección 3.1.

	Parte estructural	**Parte heurística**
Qué responde	Cuánta gente conservar, y a partir de qué nivel automatizar más ya no libera a nadie	Cuánto se ahorra, cuánto se puede invertir y cuán expuesta queda la organización
De qué sale	De contar horas: las que hace la IA, las que hay que cubrir sin ella, las que trabaja una persona	De la cuenta anterior, más primas por la fragilidad de la arquitectura
¿Usa números elegidos por el autor?	No	Sí: las primas de la Tabla 5 y el tope de descuento por respaldo
Si alguien rechaza esas primas	Sigue valiendo entera	Hay que recalcularla con otras
Dónde se desarrolla	Secciones 3.2 a 3.4 y 4.2	Secciones 3.5 a 3.7, 4.4 y 4.5

Tabla 1. Las dos partes del modelo. La Sección 4.5 mide cuánto aguanta la parte heurística si las primas están mal; la estructural no necesita esa defensa.

3.1 Datos de entrada

El modelo toma seis cantidades operativas, que se listan primero porque son las que restringieron el diseño: cada una tiene que poder contestarla un responsable de operaciones sin montar un proyecto de datos. Hacen falta cinco cantidades más, de otra naturaleza, y una sexta opcional. H_{min} es una declaración de política antes que una medición; C se lee de una factura; I, M y T_{max} describen el proyecto y no la operación. Las primas de arquitectura de la Sección 3.5 se eligen de una lista cerrada, no se cargan como números. La opcional es el respaldo externo R de la Sección 3.6, que se admite solo bajo las tres condiciones que allí se enuncian y es el único dato que baja la exposición informada. La Tabla 2 las reúne a todas.

Símbolo	Dato	Unidad
P	Dotación del área analizada	personas
N	Nómina mensual de esa área	moneda/mes
h_p	Horas de trabajo por persona y por mes	horas/mes
a	Porción del trabajo que la IA podría hacer	fracción
r	Horas de ese trabajo que una persona retiene igual ($r_n + r_p$)	fracción
η	Rendimiento que la IA alcanza realmente	fracción
H_{min}	**Horas por mes que hay que cubrir pase lo que pase**	**horas/mes**
C	**Gasto mensual de IA**	**moneda/mes**
I	**Inversión inicial**	**moneda**
M	**Mantenimiento mensual**	**moneda/mes**
T_{max}	**Horizonte con el que la organización aprueba inversiones**	**meses**
R	**Respaldo externo verificado (Sección 3.6)**	**personas**

Tabla 2. Todos los datos del modelo. Los primeros seis, en redonda, son los operativos que restringieron el diseño. El resto, en negrita, son una declaración de política (H_{min}), una cifra de factura (C), tres parámetros de proyecto y el término opcional de respaldo. Las primas de arquitectura de la Tabla 5 se eligen de una lista cerrada en lugar de cargarse como números. Presentaciones anteriores de este modelo decían que toma seis datos; ese conteo se refiere al bloque operativo solamente.

3.2 Automatización efectiva

La porción de trabajo genuinamente automatizable es menor que la técnicamente automatizable. Se aplican dos descuentos, y son independientes entre sí.

El primero, **r**, es lo que no se delega. Puede ser por norma — una ley o un regulador exigen que lo autorice una persona habilitada — o por decisión de la propia organización: la IA clasifica el reclamo, pero si el cliente amenaza con acciones legales contesta una persona. Los dos casos descuentan igual, aunque uno venga de afuera y el otro de adentro.

Los dos orígenes descuentan igual, pero conviene escribirlos por separado porque no se sostienen igual: $r = r_n + r_p$.

r_n, la parte por norma, es exógena: la fija el sector, la organización no la eligió y no la puede quitar. Ejemplo: un centro de atención telefónica de salud o de una fuerza de seguridad tiene horas que una persona retiene porque la norma lo dispone; el mismo centro, con las mismas consultas, en una cadena minorista tiene $r_n = 0$ porque no hay nada que autorizar. **r no es una propiedad de la tarea sino del sector en el que esa tarea ocurre.**

r_p, la parte por política, la fijó la organización, y la organización puede deshacerla. Ejemplo: se decidió que si el mensaje trae insultos, o habla de una falla en una promoción, contesta una persona, aunque el sistema podría contestarlo y ninguna ley lo exige. La Tabla 3 pone los dos términos lado a lado.

Término	Qué es	Quién lo fija	¿Se puede quitar?	Ejemplo
r_n (norma)	Horas que una ley o un regulador obligan a dejar en manos de una persona	El sector, desde afuera	No	Centro de atención de salud o de una fuerza de seguridad

Término	Qué es	Quién lo fija	¿Se puede quitar?	Ejemplo
r_p (política)	Horas que la organización decidió no delegar aunque podría	La propia organización	Sí, con una decisión	Si el mensaje trae insultos o habla de una falla en una promoción, contesta una persona
r	La suma de los dos	—	Solo la parte r_p	Caso de referencia: 0,20

Tabla 3. Los dos orígenes de r. Descuentan igual en la fórmula; lo que los separa es cuánto duran.

De ahí se sigue algo que conviene decir explícitamente, porque suele leerse al revés: la regulación opera como un seguro de continuidad. El mismo proyecto de automatización, idéntico en todo lo demás, produce un índice más bajo en el hospital que en la cadena minorista, porque la norma retiene horas humanas que nadie puede delegar. Lo que a corto plazo se percibe como una restricción es, en la contabilidad de este modelo, exposición que no se contrajo.

El término de política no goza de esa estabilidad. Fue una decisión, y las decisiones se revisan — típicamente bajo presión de costos, que es exactamente cuando esas horas humanas hacen falta. Dos organizaciones con el mismo IDA —el índice de exposición que define la Sección 3.7— no están entonces igual de firmes: aquella cuyo r es enteramente política sostiene su posición sobre algo que un directorio puede revertir en una reunión. La implementación de referencia pide la partición como dato **opcional de reporte**: no interviene en ningún cálculo, porque los dos términos suman, y se informa junto al índice para que esa diferencia de durabilidad quede a la vista.

r se mide en **horas que se retienen**, no en tareas que una persona toca. La distinción cambia el resultado. Si el sistema redacta la respuesta en treinta minutos y una persona la autoriza en treinta segundos, esa tarea aporta los treinta segundos y no los treinta minutos: lo que se retuvo fue la autorización, no el trabajo. Contar la tarea completa infla r, deprime a_{ef} e infla P′ — es decir, hace conservar gente que el modelo no está pidiendo. Es el error de medición más probable en la práctica, porque la lista de tareas que exigen intervención humana es fácil de conseguir y el reparto de horas dentro de cada tarea no.

El segundo, **η**, es cuánto rinde el sistema en producción y no en una demostración. No es la exactitud del modelo: es **la fracción de las horas delegadas que efectivamente deja de ser trabajo humano**. Los dos números se separan más de lo que parece, y en la misma dirección. Un sistema que acierta en ocho de cada diez casos rinde bastante menos de 0,8, porque para encontrar los dos que están mal hay que revisar los diez, y esa revisión es trabajo humano que no se eliminó. η debe estimarse entonces sobre horas efectivamente ahorradas, y no sobre una tasa de acierto informada. Son cosas distintas: r acota *qué* se puede delegar, η acota *cuán bien* se hace lo que sí se delegó.

Un punto que se confunde con frecuencia: **r no depende de la calidad del sistema**. Aunque el modelo rindiera de manera perfecta, esas horas seguirían siendo humanas. r y η —el rendimiento del sistema— son independientes por construcción: mejorar el sistema eleva η y no mueve r en un solo punto, y por eso ningún avance técnico, por grande que sea, elimina las horas que r retiene.

$$a_{ef} = a \cdot (1 - r) \cdot \eta$$

a porción automatizable, fracción de 0 a 1 · **r** porción de esas horas que una persona retiene igual, fracción · **η** fracción de las horas delegadas que deja de ser humana · $\mathbf{a_{ef}}$ lo que queda automatizado de verdad, fracción. En el caso: 0,60 · (1 − 0,20) · 0,80 = **0,384**.

La composición es multiplicativa, y la brecha resultante no es un error de redondeo. El caso de esta sección cree estar automatizando el 60 por ciento del proceso. Un quinto de esas horas se retiene igual y el sistema rinde al 80 por ciento, así que la porción realmente automatizada es 0,60 × 0,80 × 0,80 = **38,4 por ciento** — unos dos tercios de lo que se suponía. Toda cantidad posterior se calcula sobre a_{ef}, nunca sobre a.

3.3 El piso de continuidad

La organización declara H_{min}: **las horas de trabajo por mes que hay que cubrir aunque no haya IA en absoluto.** Si esas horas no se cubren, el proceso no sucede. Es una declaración de política o de norma, no una estimación que el modelo derive.

Hay una tercera fuente, y en la práctica es la más frecuente: el **contrato**. Una organización que firmó un acuerdo de nivel de servicio se comprometió a atender, y ese compromiso no dice nada sobre con qué herramienta. El cliente no aceptó «vamos a responder salvo que nuestro proveedor de IA no esté disponible»: aceptó un tiempo de respuesta. H_{min} recoge entonces lo que haya que cubrir para sostener lo firmado, y la pregunta que ordena la estimación es directa: **si mañana el sistema no está, ¿qué parte de lo que nos comprometimos sigue siendo exigible?** La respuesta casi nunca es «nada».

Se contesta contando, no modelando. La organización de esta sección razona así: si el sistema se cae, igual hay que atender 800 consultas por mes y una persona atiende dos por hora, o sea 400 horas; además alguien tiene que revisar pedidos ocho horas por día, 240 horas más. H_{min} = **640 horas**. Son horas de trabajo, no personas: pueden repartirse entre las que haga falta. Cuántas hacen falta se sigue directamente.

$$P_{min} = techo(H_{min} / h_p)$$

$\mathbf{H_{min}}$ horas por mes que hay que cubrir sin IA, horas/mes · $\mathbf{h_p}$ horas que trabaja una persona, horas/mes · $\mathbf{P_{min}}$ el piso, en personas. «Techo» redondea para arriba: media persona no cubre media guardia. En el caso: techo(640 / 160) = **4 personas**.

La Tabla 4 mueve las dos cantidades para que se vea cómo responde el piso. Sube con las horas que hay que cubrir y baja con la jornada de cada persona, y el redondeo hacia arriba nunca juega a favor: 4,375 personas son 5.

$\mathbf{H_{min}}$ (horas/mes)	$\mathbf{h_p}$ (horas/mes)	$\mathbf{H_{min} / h_p}$	$\mathbf{P_{min}}$	Lectura
640	160	4	**4**	El caso de referencia
640	320 (doble turno)	2	**2**	Las mismas horas, cubiertas por menos gente
700	160	4,375	**5**	Sesenta horas más obligan a una persona entera
320	160	2	**2**	La mitad de operación crítica, la mitad del piso
0	160	0	**0**	Nada que sostener sin IA: no hay piso

Tabla 4. El piso ante distintos valores. La tercera fila es la que suele sorprender: el cociente da 4,375 y el piso es 5, porque media persona no cubre media guardia.

3.4 Dotación a conservar

La economía sola fijaría la dotación según la porción de trabajo que todavía hacen las personas; llamemos a eso P_{econ}. La continuidad fija una cota inferior que la economía no puede cruzar, que es P_{min}. **La dotación a conservar, que se escribe P′, es la mayor de las dos** — y P′ es el número que este trabajo existe para calcular.

$$P_{econ} = techo(P \cdot (1 - a_{ef})) \qquad P' = máx(P_{econ} , P_{min})$$

P dotación actual del área, personas · $\mathbf{P_{econ}}$ la que dejaría la economía sola, personas · $\mathbf{P_{min}}$ el piso de continuidad, personas · **P′** la que hay que conservar, personas. En el caso: P_{econ} = techo(10 · 0,616) = 7, y como 7 > 4, **P′ = 7** — se liberan 3.

El operador máximo es el punto donde el modelo se aparta de un caso de negocio convencional, y es el origen de todo resultado no obvio de la Sección 4. Cuando P_{min} pasa a mandar, automatizar más deja de convertirse en gente liberada y sigue convirtiéndose en costo.

Un caso de borde merece tratamiento explícito. Si P_{min} > P, la organización ya está por debajo de la dotación necesaria para operar sin la IA. El modelo lo informa en lugar de acotarlo: es un hallazgo sobre el estado presente, no un error en los datos.

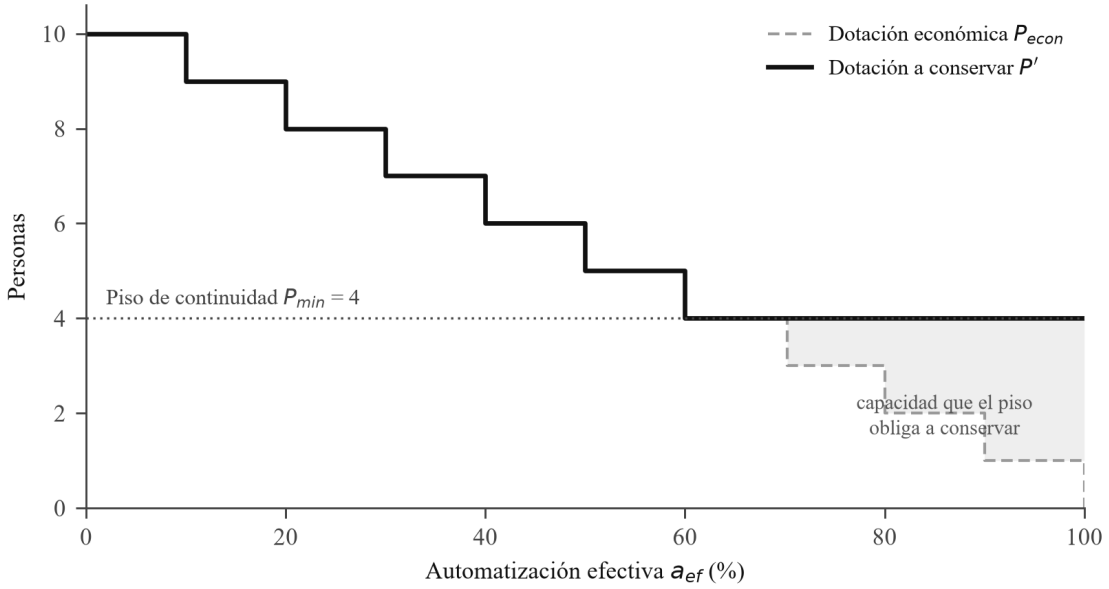


Figura 1. El piso de continuidad. El razonamiento económico solo seguiría bajando la dotación a medida que sube la automatización efectiva (línea de trazos). La dotación a conservar (línea llena) lo acompaña únicamente hasta alcanzar el piso que la organización declaró, y ahí se detiene. El área sombreada es la capacidad laboral que la continuidad obliga a conservar, y que un caso de negocio convencional habría liberado. Configuración de referencia de la Sección 4.2.

3.5 Multiplicador de riesgo y ahorro ajustado

La fragilidad de la arquitectura se cobra como un recargo sobre el gasto de IA, que se escribe λ. El multiplicador arranca en uno y acumula una prima por cada fragilidad declarada.

El recargo no es una factura: nadie le cobra a la organización ese dinero. Es una forma de anotar en la evaluación un costo que hoy no aparece en ningún lado y que va a aparecer entero un solo día, el de la caída.

Sirve la comparación con un seguro. Quien no lo contrata no gasta menos: gasta lo mismo hasta el día del accidente, y ese día paga todo junto. λ hace lo contrario: reparte ese costo futuro en cuotas mensuales, de modo que una arquitectura frágil se vea cara *mientras todavía es barato cambiarla* y no el día en que ya no se puede.

$$\lambda = 1 + \Sigma \rho_i$$

ρ_i cada prima de la Tabla 5, sin unidad · λ el multiplicador, sin unidad, arranca en 1. En el caso —una nube sin plan de contingencia— λ = 1 + 0,30 + 0,20 = **1,50**: el modelo evalúa la factura de IA como si costara un 50 por ciento más.

Condición	Prima ρ_i
La IA corre en infraestructura propia de la organización	0,02
La IA corre sobre varios proveedores de nube	0,10
La IA corre sobre un único proveedor de nube	0,30
No hay plan de contingencia documentado	+0,20
Se procesan datos sensibles fuera de la organización	+0,15

Tabla 5. Primas de arquitectura. Las tres primeras son excluyentes entre sí; las dos últimas se suman. El máximo alcanzable es λ = 1,65. Estos coeficientes son criterio experto declarado; ver la Sección 6.

El gasto de IA se comporta de una de dos maneras, y la distinción gobierna la Sección 4. Con facturación por uso escala con las horas automatizadas, $C = c \cdot P \cdot h_p \cdot a_{ef}$, donde c es el gasto por hora automatizada; con capacidad comprometida —costo fijo—, C es una constante. La división que importa es esa y no nube contra infraestructura propia: un servidor propio también tiene costos que crecen con el uso, como la energía, y una

nube puede venderse como capacidad reservada a precio fijo. Escribiendo $C_h = N / (P \cdot h_p)$ por el costo de una hora humana, el modelo tiene sentido únicamente cuando $\lambda \cdot c < C_h$, es decir, cuando la hora de IA ajustada por riesgo es más barata que la hora humana que reemplaza; de lo contrario la organización paga por automatizar. En el caso de referencia de la Sección 4.1, $c = 2$ y $C_h = 10$, y la Tabla 6 reúne estas cantidades con sus valores.

Dos precisiones sobre esa condición y sobre c. La primera: $\lambda \cdot c < C_h$ es **necesaria pero no suficiente** para que el ahorro sea positivo. La gente se libera de a una persona entera mientras el gasto de IA crece de forma continua, así que entre dos escalones se paga automatización que todavía no liberó a nadie. En el caso de referencia la organización paga 3,84 equivalentes de persona en IA y libera 3, de modo que el punto de equilibrio sobre $\lambda \cdot c$ baja de 10 a **7,81** antes de contar el mantenimiento. Con $P \cdot a_{ef} < 1$ el ahorro es directamente negativo, porque no se libera a nadie y la factura ya corre.

La segunda: c se define **por hora humana efectivamente ahorrada**, no por hora delegada al sistema. La diferencia importa al estimarlo. Un proveedor cobra por lo que se le manda, que son las horas delegadas $a \cdot (1 - r)$; las que dejan de ser humanas son menos, porque η descuenta la revisión. Tomar la tarifa del proveedor por hora delegada y usarla como c subestima la factura en un factor η. Quien prefiera trabajar con la tarifa de lista debe entonces dividirla por η, y tener presente que al hacerlo c y η dejan de ser independientes — algo que la simulación de la Sección 4.4 supone al sortearlos por separado.

Símbolo	Qué es	Unidad	En el caso
c	Lo que cuesta cada hora de trabajo que hace la IA	moneda/hora	2
C	El gasto mensual de IA. Con pago por uso crece con las horas automatizadas; con capacidad comprometida —servidores propios o capacidad reservada— es fijo	moneda/mes	$2 \cdot 10 \cdot 160 \cdot 0{,}384 = 1.228{,}80$
C_h	Lo que cuesta una hora de una persona	moneda/hora	$16.000 / (10 \cdot 160) = 10$
$\lambda \cdot c$	La hora de IA con el recargo por fragilidad	moneda/hora	$1{,}50 \cdot 2 = 3$

Tabla 6. Las cantidades de costo con los valores del caso de referencia. El modelo tiene sentido mientras la última fila sea menor que la tercera: acá, 3 contra 10.

Leído con el caso: cada hora que pasa de una persona a la IA deja de costar 10 y pasa a costar 3 una vez incluido el recargo, así que en la evaluación libera 7. Si la hora de IA recargada llegara a 10, automatizar dejaría de ahorrar, y por encima de 10 costaría dinero. Si la misma organización pagara capacidad comprometida a precio fijo, el gasto mensual no cambiaría al automatizar más; esa diferencia de comportamiento es la que separa las dos curvas de la Figura 3.

El ahorro ajustado por riesgo resta el costo de IA recargado y el mantenimiento a la nómina de la gente efectivamente liberada.

$$S = (P - P') \cdot (N / P) - C \cdot \lambda - M$$

N nómina mensual del área, moneda/mes · **N/P** lo que cuesta una persona, moneda/mes · **C** gasto mensual de IA, moneda/mes · **M** mantenimiento, moneda/mes · **S** el ahorro ajustado por riesgo, moneda/mes. En el caso: $3 \cdot 1.600 - 1.228{,}80 \cdot 1{,}50 - 500 =$ **2.456,80 por mes**.

S es una cantidad de evaluación económica, no una proyección de flujo de caja. La organización no le firma un cheque a nadie por $C \cdot \lambda$; el recargo existe para que una arquitectura frágil se vea cara mientras todavía es barato cambiarla. Un contador calculará un ahorro mayor, que es la misma expresión con $\lambda = 1$, y ambos números son correctos para sus respectivos fines. La Tabla 7 separa los términos.

Término	De dónde sale	Cuenta	Valor
Sueldos que se dejan de pagar	3 personas liberadas por lo que cuesta cada una	$3 \cdot 1.600$	+4.800

Término	De dónde sale	Cuenta	Valor
Gasto de IA con recargo	La factura del proveedor por el multiplicador de riesgo	1.228,80 · 1,50	−1.843,20
Mantenimiento	Lo que cuesta sostener el sistema cada mes	M	−500
S, el ahorro ajustado por riesgo	**Lo que informa el modelo**		**2.456,80**
Lo que calcularía un contador	El mismo cálculo sin recargo, λ = 1	4.800 − 1.228,80 − 500	3.071,20

Tabla 7. El ahorro mensual del caso de referencia, término por término. La diferencia entre las dos últimas filas, 614,40 por mes, es lo que el modelo le cobra a la fragilidad de la arquitectura y no aparece en ninguna factura.

3.6 Recupero, techo de inversión y respaldo externo

El recupero simple se sigue como T = I / S. Invertirlo contra el horizonte con el que la organización aprueba inversiones produce la cantidad que en la práctica resultó más útil.

$$I_{max} = S \cdot T_{max}$$

$\mathbf{T_{max}}$ en cuántos meses la organización exige recuperar una inversión, meses · $\mathbf{I_{max}}$ lo máximo que ese proyecto puede justificar, moneda. En el caso: 2.456,80 · 18 = **44.222**. El proyecto se presentó a 50.000.

Las dos cantidades están definidas solo para S > 0. Cuando el ahorro ajustado por riesgo es cero o negativo el proyecto no tiene recupero finito ni techo de inversión positivo, y el modelo informa eso en lugar de una cifra negativa; la simulación de Montecarlo de la Sección 4.4 — que repite el cálculo miles de veces con valores al azar — cuenta esas corridas por separado por la misma razón.

Esto reencuadra la decisión. Informar «se recupera en veinte meses» deja al directorio con una sola alternativa: aprobar o rechazar, sin nada para discutir en el medio. El modelo enuncia en cambio el monto máximo que el proyecto puede justificar, que es una posición de negociación calculada con el ahorro propio de la organización y con su propio riesgo.

Sensibilidad del techo: El techo sale del ahorro, el ahorro carga el recargo por fragilidad, y ese recargo sale de primas que fijó el criterio del autor. Por eso I_{max} no conviene leerlo como un número exacto sino como un rango. Dicho simple: si la organización acepta que su arquitectura es tan frágil como la declaró, el proyecto puede justificar hasta **44.222**; si no le asigna ningún costo a esa fragilidad — que es lo que haría un contador — puede justificar hasta **55.282**. El proyecto cuesta 50.000, justo entre los dos. Qué lado vale es exactamente lo que hay que decidir, y la Tabla 8 muestra los pasos intermedios.

Arquitectura	λ	S	I_{max}	Proyecto de 50.000
Una nube, sin plan de contingencia	1,50	2.456,8	44.222	rechazado
Una nube, con plan	1,30	2.702,6	48.646	rechazado
Multi-nube, con plan	1,10	2.948,3	53.070	aprobado
Infraestructura propia, con plan	1,02	3.046,6	54.839	aprobado
λ = 1 — lo que calcularía un contador	1,00	3.071,2	55.282	aprobado

Tabla 8. El techo de inversión en función de la fragilidad de la arquitectura, manteniendo la factura de IA constante en 1.228,80 por mes para aislar λ. Con un despliegue propio la factura misma cambiaría; la fila aísla el multiplicador, no la arquitectura entera.

Despejar λ de I_{max} = I da el punto en el que el veredicto cambia. Acá es λ = 1,24.

Ese número sirve más que una aprobación. El modelo no dice que sí ni que no. Dice: **este proyecto vale lo que cuesta si, y solo si, operar sobre un único proveedor sin una contingencia ensayada le cuesta a la**

organización menos que un 24 por ciento extra sobre su factura de IA. Esa es la pregunta que va a un directorio, porque es la única que el modelo no puede contestar en su lugar. Informar el umbral en vez del veredicto deja explícito que el coeficiente sin calibrar es lo que se está avalando. La Sección 4.5 establece qué conclusiones no dependen de ese aval.

La exposición se descuenta por respaldo externo verificado. La pregunta es la misma que cualquier organización se hace ante una ausencia: **si mañana esta área se queda sin el sistema, ¿cuántas personas de la organización saben hacer esta tarea?** Suele haberlas. Hoy cumplen otro rol y dedican su jornada entera a otra cosa, pero se las puede reasignar. La organización en conjunto funciona más lenta, porque esas personas dejan su propio trabajo, pero **el proceso no se corta**.

R es la cantidad de esas personas, fuera del área analizada, que pueden hacer el trabajo el día de una caída sin capacitación previa.

$$cobertura = mín(R / P_{min} , 1) \quad (cobertura = 0 \text{ cuando } P_{min} = 0)$$

R personas de fuera del área que hoy pueden hacer la tarea, personas · **cobertura** qué parte del piso cubren, fracción de 0 a 1, topeada en 1. En el caso R = 0, así que **cobertura = 0** y el índice no recibe descuento.

«mín» quiere decir quedarse con el menor de los dos números. Acá funciona como un tope: la cobertura nunca pasa de 1, que es tener cubierto el piso entero. La Tabla 9 la calcula para cuatro valores de R en el caso de referencia, donde el piso es de 4 personas.

R (personas de afuera que saben la tarea)	R / P_{min}	cobertura	Descuento (cobertura · 0,7)	IDA
0	0 / 4 = 0	0	0	58
2	2 / 4 = 0,5	0,5	0,35	37
4	4 / 4 = 1	1	0,70	17
6	6 / 4 = 1,5	mín(1,5 ; 1) = 1	0,70	17

Tabla 9. Cómo se halla la cobertura en el caso de referencia. Con 2 personas se cubre la mitad del piso. Con 6 el cociente da 1,5, pero el tope lo deja en 1: las dos que sobran no bajan más la exposición. En ninguna fila cambia P′, que sigue en 7.

Dos decisiones de diseño restringen a R. Primero, se admite solo cuando se declaran conjuntamente tres condiciones: que esas personas hayan hecho este proceso, que el procedimiento manual esté documentado, y que el traspaso se haya ensayado. Si falta alguna, R se fuerza a cero. R es el único dato que baja el riesgo informado, y por lo tanto el más expuesto a un reporte optimista. Segundo, la cobertura descuenta la exposición pero nunca la elimina: el descuento máximo es 0,7, porque quien viene de otra área abandona su propio puesto, no hace la tarea todos los días y carece del contexto acumulado.

Conviene señalar que R no reduce P′. El respaldo externo baja cuán expuesta está la organización, no cuánta gente necesita. Es una decisión de diseño deliberada: **R se considera una mitigación de emergencia y no una justificación de antemano para reducir la dotación permanente del área**. Esas personas tienen su propio trabajo, y contarlas dos veces — como respaldo y como dotación — dejaría el piso cubierto solo en el papel.

3.7 El índice

El índice compone los tres factores que determinan la exposición: cuánto del trabajo depende ahora del sistema, cuán frágil es la arquitectura que lo sostiene, y qué parte del piso de continuidad está cubierta desde afuera.

$$IDA = mín(a_{ef} \cdot \lambda \cdot (1 - cobertura \cdot 0{,}7) \cdot 100 , 100)$$

Los tres factores ya definidos: $\mathbf{a_{ef}}$ cuánto del trabajo depende del sistema, **λ** cuán frágil es la arquitectura, **cobertura** cuánto está cubierto desde afuera. El resultado va de 0 a 100, sin unidad. En el caso: 0,384 · 1,50 · 1 · 100 = 57,6, que se informa como **58**.

Los extremos son interpretables: 0 denota dependencia no medible, 100 denota la máxima dependencia que el modelo representa. El tope es necesario porque el producto sin acotar alcanza 165 con $a_{ef} = 1$ y $\lambda = 1{,}65$; todo lo que supere 100 ya es exposición máxima, y truncar preserva un significado estable para la escala. Las bandas informadas son 0–30 resiliente, 30–60 vigilancia, 60–100 crítico, y la Figura 2 muestra cómo se llega a cada una.

El truncamiento tiene un costo, y conviene declararlo. Dos organizaciones cuyo producto sin acotar vale 105 y 165 informan las dos un índice de 100, y sin embargo la segunda está bastante más expuesta que la primera. Donde esa diferencia importe — al comparar unidades de negocio entre sí, o al seguir a una misma organización en el tiempo — corresponde informar junto al índice la **exposición bruta** $E = a_{ef} \cdot \lambda \cdot (1 - \text{cobertura} \cdot 0{,}7) \cdot 100$, sin el mínimo. El índice sigue siendo la cifra que se comunica; E es la que conserva el orden por encima del tope.

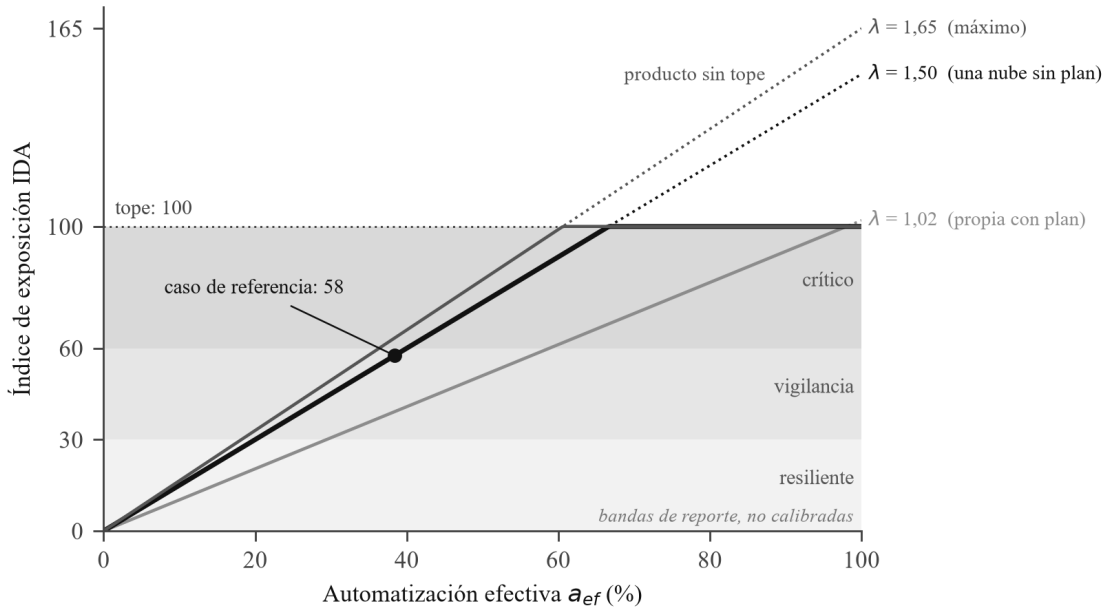


Figura 2. Cómo se arma el índice y dónde se corta, sin respaldo externo. Cada línea es una arquitectura: $\lambda = 1{,}02$ (infraestructura propia con plan), 1,50 (una nube sin plan, la del caso) y 1,65 (la máxima que admite la Tabla 5). El índice sube en línea recta con la automatización efectiva hasta tocar 100 y ahí se corta; la parte punteada es el producto sin tope, que con $\lambda = 1{,}65$ llegaría a 165. Las franjas son las bandas de reporte, una convención declarada. El punto es el caso de referencia: $0{,}384 \cdot 1{,}50 \cdot 100 = 57{,}6$, informado como 58.

El ahorro y la exposición se informan por separado y no se combinan en un puntaje único, porque se mueven de manera independiente. Dos organizaciones pueden ahorrar lo mismo todos los meses y estar en situaciones completamente distintas: una automatizó un tercio de su trabajo repartido en dos proveedores y puntúa poco más de veinte; la otra automatizó casi todo sobre un único proveedor sin contingencia ensayada y puntúa cerca de cien. El ahorro mensual no las distingue. Fundir los dos números en uno ocultaría precisamente el compromiso que el modelo existe para exponer.

4. Propiedades y ejemplo trabajado

4.1 Caso de referencia

El caso de la Sección 3, completo. Una organización automatiza su centro de atención al cliente, donde diez personas contestan correos, llamadas y mensajes de WhatsApp. La nómina mensual del área es de 16.000 y cada una trabaja 160 horas por mes. El 60 por ciento del trabajo es automatizable, y de esas horas un 20 por ciento la retiene igual una persona, por norma o por política; el sistema rinde al 80 por ciento. Hay 640 horas por mes que deben cubrirse pase lo que pase. El proyecto cuesta 50.000 con 500 por mes de mantenimiento, corre sobre un único proveedor de nube sin plan de contingencia, y se evalúa contra un horizonte de dieciocho

meses.

Cantidad	Valor
Automatización efectiva a_{ef}	0,384
Piso de continuidad P_{min}	4 personas
Dotación económica P_{econ}	7 personas
Dotación a conservar P'	7 personas (3 liberadas)
Multiplicador de riesgo λ	1,50
Ahorro ajustado por riesgo S	2.456,80 por mes
Recupero T	20,4 meses
Techo de inversión I_{max}	44.222
Índice IDA	58 (vigilancia)

Tabla 10. Caso de referencia. La línea decisiva es la anteúltima: el proyecto se presentó a 50.000 y el modelo enuncia que para esta organización, con este nivel declarado de riesgo, vale como máximo 44.222. La Tabla 8 da la banda alrededor de esa cifra y el umbral en el que el veredicto se invierte.

4.2 Existe un óptimo de automatización con costo variable

Fijando r = 0 —nada exige firma humana— y $\eta = 1$ —el sistema rinde al ciento por ciento— para aislar el efecto, y dejando crecer la porción automatizada, aparece un resultado que contradice la intuición sobre la que se construye el caso de negocio.

Automatización efectiva	Promesa ingenua	Ahorro real	Recupero	IDA
60% (óptimo de este caso)	6.220	**6.220**	**8 meses**	90
80%	8.460	5.260	10 meses	100
100%	10.700	4.300	12 meses	100

Tabla 11. Pasado el piso de continuidad la organización queda más pobre y más dependiente al mismo tiempo. La columna ingenua supone que cada hora automatizada es un sueldo menos.

El mecanismo es el operador máximo de la Sección 3.4. Una vez que P_{econ} cae por debajo de P_{min}, el piso manda: la dotación liberada deja de crecer mientras las horas automatizadas, y por lo tanto la factura de IA, siguen creciendo. El ahorro baja. La ubicación del óptimo no es propia de cada caso: admite forma cerrada.

Proposición (el nivel en el que el piso de continuidad empieza a mandar). Para $0 \le P_{min} \le P$, con facturación por uso, $\lambda \cdot c < C_h$ y la estructura de dotación y de costos de la Sección 3, el ahorro ajustado por riesgo S se maximiza en

$$a^* = 1 - P_{min} / P$$

a* el nivel de automatización efectiva donde el piso empieza a mandar, fracción. Contiene solo el piso y la dotación: ningún costo, ningún coeficiente de riesgo. En el caso: 1 − 4/10 = **0,60**.

la menor automatización efectiva en la que el piso de continuidad pasa a mandar, y S es estrictamente decreciente para $a_{ef} > a^*$. El ahorro en el óptimo vale

$$S(a^*) = (P - P_{min}) \cdot h_p \cdot (C_h - \lambda \cdot c) - M$$

$\mathbf{C_h}$ lo que cuesta una hora humana, moneda/hora · **c** lo que cuesta una hora automatizada, moneda/hora · $\boldsymbol{\lambda}$ · **c** esa hora ajustada por riesgo. En el caso: 6 · 160 · (10 − 3) − 500 = **6.220 por mes**.

Esquema de demostración. La dotación liberada $k = P - P'$ es una función escalonada de a_{ef}: se liberan k personas para a_{ef} en [k/P, (k+1)/P), hasta el máximo $k = P - P_{min}$ que impone el piso. Dentro de cada escalón

el término de nómina es constante mientras el término de costo crece linealmente, de modo que S alcanza su máximo sobre el escalón en su borde izquierdo, donde $S = k \cdot h_p \cdot (C_h - \lambda \cdot c) - M$. Eso es creciente en k siempre que $\lambda \cdot c < C_h$, así que el máximo global está en el mayor k alcanzable, cuyo borde izquierdo es $a^* = (P - P_{min})/P$. Pasado a* no se libera más gente mientras el costo sigue acumulándose. □

Dos aclaraciones acotan el alcance de la proposición. La primera es el dominio: cuando $P_{min} > P$ la expresión da un valor negativo y deja de representar un nivel de automatización, porque la organización ya está por debajo de la dotación que necesita — el caso de borde de la Sección 3.4. La segunda es la factibilidad: a* es el óptimo **estructural**, y la automatización efectiva alcanzable tiene su propio techo, $a_{ef}^{máx} = a \cdot (1 - r) \cdot \eta$ con a = 1. Si ese techo queda por debajo de a*, el piso nunca llega a mandar: con r = 0,20 y η = 0,80 el techo es 0,64, apenas por encima del a* = 0,60 del caso.

Determinar entonces dónde cae el máximo exige cuidado, porque el ahorro es una función escalonada. Dentro de cada escalón la gente liberada no cambia y el costo de IA sí crece, así que S decrece: el máximo alcanzable no está en el techo sino en el **borde izquierdo del último escalón que el techo permite**: la parte entera de $P \cdot a_{ef}^{máx}$, dividida por P. Con r = 0,30 y η = 0,80 el techo es 0,56 y el borde es 0,50: operar en 0,50 libera cinco personas y deja **5.100** por mes, mientras que operar en 0,56 libera las mismas cinco y deja **4.812**. Los 288 de diferencia son IA que se paga sin liberar a nadie. Los dos puntos coinciden solo cuando $P \cdot a_{ef}^{máx}$ es entero. Conviene entonces distinguir el **óptimo estructural** del **óptimo factible**, que coinciden cuando $a^* \leq a_{ef}^{máx}$.

La Tabla 12 recorre ese razonamiento con números, en la misma configuración de la Tabla 11. Hasta el 60 por ciento cada escalón libera una persona más y el ahorro sube. Desde el 60 el piso fija la dotación en cuatro, no se libera a nadie más, y el único término que sigue moviendo es el costo de IA, que crece: por eso el ahorro baja.

a_{ef}	$P_{econ} = techo(10 \cdot (1 - a_{ef}))$	$P' = máx(P_{econ}, 4)$	Gente liberada k	S
10%	9	9	1	620
30%	7	7	3	2.860
50%	5	5	5	5.100
60%	**4**	**4**	**6**	**6.220**
80%	2	4	6	5.260
100%	0	4	6	4.300

Tabla 12. La función escalonada, con r = 0 y η = 1. En el 60 por ciento P_{econ} toca el piso y se detiene: de ahí en adelante la columna de gente liberada queda clavada en 6 y S empieza a caer. Ese punto es a*.

El punto lo define el piso y no un argumento de optimalidad: es la menor automatización efectiva en la que P_{min} empieza a mandar, y bajo los supuestos enunciados coincide con el máximo del ahorro ajustado por riesgo. En la configuración de referencia $a^* = 1 - 4/10 = 0{,}60$ y $S(a^*) = 6 \cdot 160 \cdot (10 - 3) - 500 = 6.220$, que es la primera fila de la Tabla 11. **La ubicación del óptimo depende entonces del piso declarado y de la dotación, y de nada más.** Los sueldos, el costo unitario y λ cambian su altura, no su posición — un hecho que la Sección 4.5 pone a trabajar. Con costo fijo ese mismo a* marca el comienzo de la meseta de la Sección 4.3, y como $I_{max} = S \cdot T_{max}$, el techo de inversión se maximiza en el mismo punto. La Tabla 11 fija r = 0 y η = 1 para que a_{ef} coincida con a; la proposición está enunciada sobre a_{ef} y vale para cualquier r y η. Es la contraparte a nivel de firma del resultado de sobreautomatización de [14].

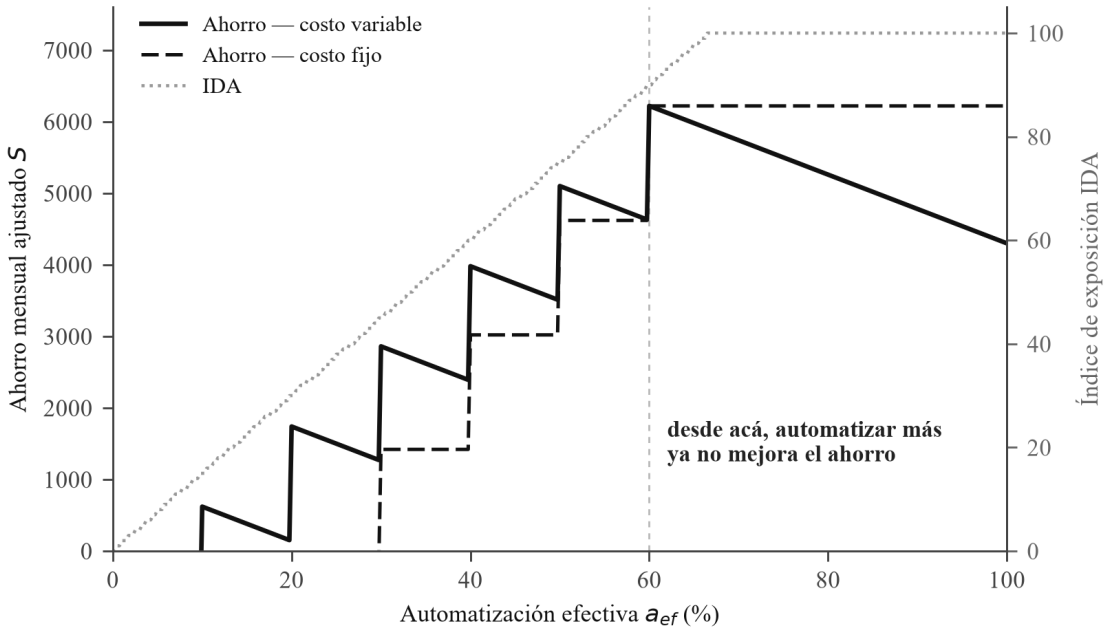


Figura 3. Ahorro contra exposición. Una vez que el piso manda, en el 60 por ciento, las dos estructuras de costo divergen: con costo variable el ahorro baja, porque las horas automatizadas siguen acumulándose mientras la dotación liberada no; con costo fijo se aplana. El índice de exposición sube en ambos casos. A la derecha de la línea de trazos, automatizar más no compra ahorro adicional en ninguno de los dos regímenes y sigue comprando dependencia. El costo fijo se fija en el gasto que la rama variable tiene en $a_{ef} = 0{,}60$, de modo que ambas curvas coinciden ahí y la comparación aísla la estructura de costo y no el nivel de gasto. Los dientes de sierra no son un error: la gente se libera de a una persona entera mientras la factura de IA crece de forma continua, así que entre dos escalones el ahorro baja y en cada escalón salta. El eje no muestra valores negativos: por debajo del 10 por ciento con costo variable, y del 30 por ciento con costo fijo, el ahorro es menor que cero.

4.3 Con costo fijo el ahorro se aplana en lugar de caer

El resultado anterior supone que la IA se factura por unidad de uso. Cuando la organización opera su propia infraestructura, C es constante, y dado que la dotación liberada es no decreciente en a_{ef} mientras todos los demás términos están fijos, S es no decreciente. En la misma configuración de la Tabla 11 con un costo mensual fijo, el ahorro es idéntico al 60 y al 100 por ciento de automatización efectiva.

La consecuencia no es que el compromiso desaparezca sino que cambia de moneda. Con costo fijo, automatizar pasado el piso ya no empobrece a la organización, y sin embargo el índice sigue subiendo de 90 a 100 en ese mismo intervalo. Automatizar de más compra dependencia a cambio de nada. Con costo variable la organización pierde plata y resiliencia juntas; con costo fijo pierde solo resiliencia, que es más difícil de ver en un balance y más caro de reparar después.

La distinción que esto vuelve visible conviene enunciarla sin vueltas: **automatización no implica autonomía**. Una organización puede automatizar una porción creciente de su trabajo y, al mismo tiempo, volverse menos capaz de operar por sí misma. Las dos cantidades se mueven de manera independiente, y por lo general solo se mide una.

4.4 Incertidumbre

Una aclaración para quien no trabaja con simulación. Hasta acá cada cálculo usó un único valor por dato: la IA rinde al 80 por ciento, la hora cuesta tanto. Nadie sabe esos valores con certeza antes de aprobar el proyecto. La técnica de **Montecarlo** resuelve eso repitiendo el mismo cálculo miles de veces: en cada vuelta elige al azar un valor para cada dato incierto, dentro del rango que el analista considera posible, y anota el resultado. Al final no queda un número sino un conteo — en cuántas de las vueltas el proyecto se recuperó a tiempo, en cuántas no. Es lo que haría alguien que, sin saber cuánto va a rendir la IA, probara todos los valores razonables y contara qué pasa.

Las estimaciones puntuales de a, η, el costo unitario y λ rara vez son defendibles en el momento en que se aprueba un proyecto. Una capa de Montecarlo sortea cada una de forma independiente de una distribución uniforme sobre el rango que el analista declara, mantiene el resto de los datos en sus valores declarados, e informa la proporción de corridas en las que la inversión se recupera dentro de T_{max} bajo el escenario declarado. La porción retenida r deliberadamente no se sortea: es una decisión ya tomada — lo que la norma exige retener más lo que la organización decidió no delegar —, y cambiarla es un escenario nuevo a simular y no un sorteo al azar. Tampoco se sortean P, N, h_p ni H_{min}: son cantidades que la organización tiene o declara, no incertidumbres sobre ella. Sortearlas sería simular otra organización en lugar de la incertidumbre que enfrenta esta.

Cantidad sorteada	Distribución	Rango
Porción automatizable a	uniforme	0,50 – 0,70
Rendimiento η	uniforme	0,65 – 0,90
Costo por hora automatizada c	uniforme	1,50 – 4,00
Multiplicador de riesgo λ	uniforme	1,30 – 1,70

Tabla 13. Especificación del muestreo para el caso de referencia. Fijos en los valores de la Sección 4.1: r = 0,20, P = 10, h_p = 160, N = 16.000, P_{min} = 4, M = 500, I = 50.000, T_{max} = 18. Sorteos: 10.000, con el generador mulberry32 y semilla 7. El rango de λ se extiende algo más allá del 1,65 alcanzable desde la Tabla 5 porque la simulación trata la fragilidad como una incertidumbre continua y no como una selección de la lista cerrada de primas.

En el caso de referencia la simulación dio 10.000 vueltas. En cada una sorteó los cuatro datos de la Tabla 13, dejó fijo el resto, y se fijó si la inversión se recuperaba dentro de los dieciocho meses. Sobre esas 10.000 vueltas la inversión se recupera a tiempo en el **25,4 por ciento** de las corridas, con un 0,4 por ciento que devuelve ahorro negativo y un 6,4 por ciento que recupera recién más allá de los sesenta meses. Esa cifra, y no su precisión, es el hallazgo: con esos rangos el proyecto se parece más a una apuesta que a un plan, y la palanca que mueve el número casi nunca es automatizar más sino reducir la fragilidad de la arquitectura o la inversión inicial.

Dos salvedades gobiernan cómo puede leerse esa cifra. Los rangos son **escenarios declarados, no distribuciones empíricas de probabilidad**: la uniforme dice que el analista considera plausible el intervalo y no tiene una opinión dentro de él, no es una densidad ajustada a datos. La cifra es entonces la porción de corridas que recuperan bajo el escenario declarado, y no la probabilidad de que este proyecto funcione. Segundo, las cuatro cantidades se sortean de forma independiente, cosa que es improbable que se cumpla: la arquitectura y el costo unitario se mueven juntos, y una organización que acepta una arquitectura frágil suele ser la que menos paga por hora. Un muestreo correlacionado puede cambiar la distribución resultante de manera sustantiva, y establecer cómo exigiría una estructura de correlación empírica o por escenarios que este trabajo no tiene. El supuesto de independencia es un supuesto, no un hallazgo.

La implementación usa un generador con semilla, de modo que la cifra es exactamente reproducible: cualquier lector que abra la implementación publicada con estos rangos obtiene 25,4 por ciento. El error de muestreo con esta cantidad de sorteos es de 0,44 puntos porcentuales, y volver a correrla con otras semillas devuelve valores entre 24,6 y 25,9 por ciento, consistentes con ese error. Informar la semilla importa acá por una razón concreta: una implementación anterior sin semilla del mismo modelo devolvía 26 por ciento, porque el valor subyacente cae cerca de un borde de redondeo. Un resultado de Montecarlo citado en un trabajo sin su semilla no se puede verificar, solo volver a correr.

4.5 Robustez de las conclusiones frente a las primas

Las primas de la Tabla 5 son criterio experto declarado, lo que invita a la objeción de que las conclusiones del modelo descansan sobre números afirmados. La objeción no puede responderse aquí con calibración, pero sí puede acotarse. Se perturbó cada prima en un ±50 por ciento, tanto en las $3^5 = 243$ combinaciones de una grilla de tres niveles —cada prima en −50 por ciento, nominal o +50 por ciento— como sobre 20.000 sorteos con cada prima uniforme en ese intervalo, y se examinaron cuatro propiedades.

Propiedad	Resultado bajo perturbación de ±50%
Ubicación del óptimo a*	invariante — una sola ubicación para todo λ
Existencia de un óptimo interior	vale mientras $\lambda < C_h/c = 5$: 3,0× el máximo nominal de 1,65, y 2,5× el 1,975 que se alcanza al perturbar +50%
Orden de las tres infraestructuras excluyentes, a gasto de IA fijo	preservado en el 100,0% de 20.000 sorteos, pero ±50% es el umbral exacto a partir del cual el orden puede invertirse
Orden completo de las 12 configuraciones	idéntico en solo el 2,9% de las 243 combinaciones y el 7,1% de los sorteos

Tabla 14. Robustez ordinal. Las tres primeras propiedades sobreviven; la cuarta no, y la razón se explica abajo.

La primera propiedad es inmediata a partir de la proposición de la Sección 4.2: $a^* = 1 - P_{min}/P$ no contiene ningún coeficiente de riesgo, y un barrido numérico de a_{ef} sobre [0,1] devuelve la misma ubicación para todo λ alcanzable. La segunda se sigue de la condición $\lambda \cdot c < C_h$ de la Sección 3.5, que en el caso de referencia se satisface con un factor de tres de margen. La tercera es la propiedad para la que el modelo se usa realmente: elegir entre arquitecturas. Conviene leerla por lo que es, un orden inducido por las primas de la Tabla 5 con el gasto de IA mantenido constante, y no un orden de arquitecturas completas: un despliegue propio cambia la factura entera, como registra la nota de la Tabla 8. Lo que se muestra estable es el ordenamiento que imponen las primas declaradas, no la economía completa de cambiar de proveedor.

La tercera exige una precisión que la fortalece en lugar de debilitarla. Preservar el orden en todos los sorteos no es evidencia de un margen amplio: dos primas $\rho_i > \rho_j$ pueden invertirse solo cuando el factor de perturbación f supera $(\rho_i - \rho_j)/(\rho_i + \rho_j)$, que para una nube contra multi-nube es exactamente 0,50 — se habla de inversión del orden, no de inversión financiera. Con ±50 por ciento el orden de arquitecturas está por lo tanto en su borde y no cómodamente adentro, y el 100 por ciento debe leerse como una cota ajustada y no como holgura. La inversión se vuelve materialmente probable bastante más allá: el orden sobrevive en el 97,7 por ciento de los sorteos con ±60 por ciento y en el 73,9 por ciento con ±100 por ciento. El enunciado correcto es que el orden que inducen las primas es robusto a cualquier error de estimación de ellas menor a un factor de tres entre una nube y multi-nube, siendo ese factor su cociente nominal.

Un ejemplo con números muestra de dónde sale ese umbral. ρ_i y ρ_j son simplemente dos primas de la Tabla 5 — la mayor y la menor del par que se compara — y f es cuánto se las mueve al azar, en proporción: f = 0,50 quiere decir hasta un 50 por ciento arriba o abajo. Para una nube (0,30) contra multi-nube (0,10), el umbral es (0,30 − 0,10) / (0,30 + 0,10) = 0,20 / 0,40 = **0,50**. El peor caso es bajar la mayor y subir la menor a la vez: 0,30 · (1 − 0,50) = 0,15 y 0,10 · (1 + 0,50) = 0,15. Con exactamente un 50 por ciento quedan empatadas, y solo con más de eso se dan vuelta.

El ejercicio también deja a la vista una afirmación incrustada en la Tabla 5 que es más fácil de ver que de defender: la prima por ausencia de plan de contingencia, 0,20, es exactamente la diferencia entre provisión sobre una nube y sobre varias. El modelo sostiene entonces que una contingencia ensayada vale precisamente lo mismo que un segundo proveedor. Eso es una elección de coeficiente y no un hallazgo, y está entre las primeras cantidades que el ejercicio de calibración de la Sección 6 debería poner a prueba.

El cuarto resultado es negativo y se informa en lugar de omitirse. El ordenamiento completo de las doce configuraciones seleccionables no es estable, pero la inestabilidad es local y su causa es estructural y no estadística. Dos pares cargan λ idéntico en los valores nominales: multi-nube sin plan empata con una sola nube con plan en 1,30, y los mismos dos con datos sensibles empatan en 1,45. Como los dos pares se diferencian por la misma cantidad, la prima de datos se cancela y **los dos empates se rompen siempre en espejo**, en la dirección que marque el signo de una única expresión. Eso solo ya deja el orden completo en la mitad de los sorteos, sin que nada sustantivo se haya movido. La caída del 50 por ciento al 7,1 la producen otros pares, los que están muy cerca sin estar empatados: entre 1,22 y 1,25 hay 0,03, y hay tres saltos de 0,05. La perturbación mediana es de cuatro inversiones sobre sesenta y seis pares. **La consecuencia práctica es que el modelo no debería usarse para separar dos arquitecturas cuyos multiplicadores difieran en menos de**

0,05 aproximadamente.

Tomado junto con la Sección 3.6, la posición es esta: las conclusiones estructurales del modelo — dónde está el óptimo, qué arquitectura conviene — son robustas a los coeficientes, mientras que los veredictos sobre un proyecto concreto no lo son, y por esa razón se informan como umbral. El análisis de robustez no valida los valores de las primas; evalúa si las conclusiones cualitativas del modelo dependen críticamente de ellos. Las primas siguen requiriendo calibración; lo que esta sección establece es qué afirmaciones la están esperando y cuáles no. El análisis es determinístico con semilla fija — generador mulberry32, semilla 7, la misma que usa la implementación de referencia — y se distribuye con el código fuente.

Hay algo en esos rangos que conviene decir, porque cambia cómo se lee todo lo anterior. Con a entre 0,50 y 0,70 y η entre 0,65 y 0,90, la automatización efectiva queda acotada entre 0,26 y **0,504**, siempre por debajo del a* = 0,60 de este caso. **El piso de continuidad no se activa en ninguno de los 10.000 sorteos.** La simulación mide entonces la incertidumbre del proyecto en el régimen previo al piso, y no pone a prueba el resultado de la Sección 4.2. Que subir a o η rara vez mejore el recupero dentro de estos rangos no se debe al piso sino al descuento $(1 - r)$ y al escalón: en buena parte de la caja de muestreo la gente liberada queda clavada en tres mientras el gasto de IA sigue subiendo. Un escenario que sí ejercite el piso pide rangos de a y η bastante más altos, y queda para quien quiera repetir el ejercicio con el código.

Un límite de este ejercicio conviene enunciarlo sin vueltas, porque es fácil leer la sección como si estableciera más de lo que establece. Lo que acá se perturba son los *valores* de las primas, dentro de la forma funcional que el modelo ya supone: la exposición como el producto $a_{ef} \cdot \lambda$, descontado multiplicativamente por la cobertura, y el recargo aplicado sobre el gasto de IA. **La incertidumbre de parámetro no es incertidumbre de forma funcional.** Nada en este análisis establece que la composición multiplicativa sea la correcta, que una suma ponderada no se comportaría distinto, ni que la exposición sea la cantidad adecuada en la que esos factores deban componerse. Son preguntas sobre la especificación y no sobre sus coeficientes, y el ejercicio de calibración de la Sección 6 tampoco las zanja. Son la objeción más interesante a este trabajo, y este trabajo no la contesta.

5. Verificación y reproducibilidad

El modelo se publica junto con una implementación ejecutable que corre íntegramente en el navegador, sin componente de servidor y sin transmitir los datos ingresados. Cualquier lector puede por lo tanto reproducir cada cifra de este trabajo sin instalar software, sin registrarse, y sin exponer datos operativos a un tercero. La implementación está disponible en **https://modelo-ida.web.app** y su código fuente en **github.com/All-Aideas/Modelo-IDA**.

La corrección se verifica con una batería de 25 casos de borde distribuida con el código fuente. La batería no compara el motor contra sí mismo: sus valores esperados se calculan con una reimplementación independiente de las fórmulas tal como fueron publicadas, de modo que cualquier divergencia entre el modelo documentado y el código en ejecución hace fallar la prueba. Los casos cubren los bordes donde este tipo de modelos se rompe, entre ellos un piso superior a la dotación actual, un área de una sola persona, un área de mil personas, división por cero en el término de cobertura, una hora de IA más cara que una hora humana, ambos extremos de λ y del horizonte de aprobación, respaldo declarado pero no verificado, y ambas estructuras de costo de la Sección 4.3. A la fecha de esta versión la batería pasa completa: 25 casos, ninguna falla. La configuración de referencia devuelve $P' = 7$, $S = 2.456{,}80$, un recupero de 20,4 meses y un índice de 58, y cada cifra informada en la Sección 4 la reproduce la implementación publicada en lugar de estar transcrita a este documento.

La implementación, las fórmulas, la batería de pruebas y este documento se publican bajo licencia MIT y quedan depositados con un identificador permanente [2]. El análisis de robustez de la Sección 4.5 se distribuye junto a ellos como un script independiente con semilla fija, y sus resultados.

6. Límites

Nueve límites condicionan cómo deben leerse los resultados, y se enuncian aquí en lugar de dejarlos para que el lector los descubra.

Los coeficientes son criterio experto. Las primas de la Tabla 5 y el tope de descuento de 0,7 se fijaron a partir de la práctica, no se calibraron contra un conjunto de incidentes. Son parámetros de diseño del modelo. La consecuencia inmediata es que las comparaciones dentro de una misma arquitectura son significativas, mientras que los valores absolutos entre organizaciones muy distintas deben tomarse con cautela. Calibrar contra un corpus de caídas documentadas de proveedores es la extensión más valiosa disponible y la que el autor considera el principal trabajo futuro. La Sección 4.5 acota, pero no elimina, las consecuencias de este límite. Las bandas informadas — 0–30 resiliente, 30–60 vigilancia, 60–100 crítico — son una convención de reporte declarada, no una partición derivada empíricamente.

Las horas liberadas se convierten en puestos eliminables. La rama económica supone que las horas que la IA retira se traducen en gente que la organización deja de necesitar. En la práctica una organización puede reasignar a esas personas, absorber crecimiento sin contratar, o reducir horas extra en lugar de dotación. En todos esos casos el ahorro existe pero no tiene la forma que el modelo le da. P' debe leerse entonces como capacidad laboral que ya no se requiere, no como una instrucción de despido, y cuando no se pretende reducir, S es el techo de lo que podría ahorrarse y no lo que se ahorrará.

El multiplicador se aplica al gasto de IA, no al impacto de la caída. λ recarga el costo de la IA porque esa es una cifra que la organización tiene, mientras que el costo de no operar por lo general no lo es. Esto produce un artefacto contraintuitivo entre arquitecturas de costo muy distinto: un despliegue propio, más seguro y más caro, puede cargar una prima absoluta mayor que una API frágil y barata. Dentro de una misma arquitectura la comparación es sólida, que es como se usa el modelo; entre arquitecturas, la cantidad a comparar es el índice y no la prima monetaria. Anclar la prima a un costo horario de no operación es la mejora pendiente más importante.

Alcance: El modelo aborda costo y continuidad operativa. No modela ingresos perdidos durante una caída, daño reputacional, sanciones regulatorias, ni el riesgo de que un proveedor degrade un modelo sin retirarlo, que el episodio de junio de 2026 sugiere que merece tratamiento aparte. Dos organizaciones con el mismo IDA pueden por lo tanto sufrir pérdidas muy distintas ante la misma interrupción: el índice mide la exposición a una caída, no su costo.

El índice es ciego al margen por encima del piso. Dos organizaciones con el mismo a_{ef} y el mismo λ reciben el mismo índice tanto si la dotación conservada queda muy por encima del piso de continuidad como si queda exactamente sobre él, y el índice tampoco reacciona al caso de borde $P_{min} > P$ tratado en la Sección 3.4, aunque el modelo informe ese caso por separado. La distancia al piso tiene sentido operativo y la formulación actual no la transporta. La reparación natural es una segunda cantidad informada, y no un cambio en el índice: un margen de continuidad $CM = (P' - P_{min})/P'$, que vale cero cuando la dotación conservada queda exactamente sobre el piso y se acerca a uno cuando tiene holgura; queda indefinido para $P' = 0$, el caso de un área totalmente automatizada sin piso declarado, y ahí corresponde informarlo como no aplicable. Esa definición tiene a su vez un punto ciego que conviene declarar antes de que alguien la implemente: como P' vale P_{min} siempre que el piso mande, CM da cero tanto para una organización que quedó justo sobre el piso como para una que ya está por debajo de él, que son situaciones opuestas. Separarlas exige comparar la dotación actual P contra el piso, y no la conservada P'. Informado al lado del índice en lugar de fundido dentro de él, preservaría la separación entre ahorro y exposición que defiende la Sección 3.7, devolviendo la información que el índice descarta. No está implementado acá, y se ofrece como la extensión concreta que este límite reclama.

El piso es capacidad requerida, no capacidad disponible. P_{min} se deriva de las horas que la organización declara que debe cubrir, y el modelo supone que la gente conservada todavía puede cubrirlas. Ese supuesto se debilita precisamente a medida que la automatización avanza: las habilidades que no se ejercitan se degradan, y quien supervisó un sistema durante dos años no es quien corría el proceso a mano antes. El modelo da entonces una cota inferior de la dotación requerida, y la brecha entre capacidad requerida y disponible queda

fuera de su alcance. Cuantificar esa brecha es la continuación natural de este trabajo.

El mismo cociente arrastra un segundo supuesto, más fuerte todavía: al dividir horas por horas trata a las personas como **intercambiables**. En la práctica H_{min} casi nunca es un bloque homogéneo. Si de las 640 horas del caso hay 240 que solo puede cubrir alguien con una habilitación concreta, el piso real no es techo(640/160) = 4 sino la suma de los pisos por perfil, que puede ser mayor. La lectura correcta es entonces aplicar el piso por familia de habilidades y sumar, y el número único que el modelo informa vale cuando las horas críticas son razonablemente sustituibles entre sí. Cuando no lo son, P_{min} subestima.

El episodio de junio de 2026 fue de un modelo, no de un proveedor. La directiva afectó a dos modelos nombrados; los demás modelos del proveedor siguieron disponibles [6], de modo que una organización con una contingencia ensayada hacia otro modelo del mismo proveedor siguió operando. La Tabla 5 cobra concentración de infraestructura y no lleva ninguna prima por depender de un solo modelo. El episodio que motiva este trabajo no está entonces del todo capturado por el modelo que el trabajo propone: una organización que corre un modelo de un proveedor de frontera está más expuesta de lo que su índice indica. Una prima de concentración de modelo es la primera adición estructural que la tabla requiere. Los datos del supervisor apuntan en la misma dirección: en la encuesta británica de 2024 los tres principales proveedores de modelo concentraban el 44 por ciento del total informado contra el 73 por ciento de nube, y la cifra de modelo había subido desde el 18 por ciento de 2022 mientras la de nube bajaba [9]. La concentración en la capa de modelo es del mismo orden que en la de infraestructura y crece más rápido, mientras que la Tabla 5 cobra solo esta última. Acá no se propone ningún valor provisorio para esa prima. La evidencia acota su orden de magnitud y no su tamaño, y afirmar un coeficiente para la única dependencia que este trabajo acaba de mostrar que todavía no puede medir sería repetir, en un lugar nuevo, la debilidad que la Sección 4.5 existe para acotar.

La parte de r que una decisión puede deshacer. El modelo trata r como un dato del mismo tipo que los demás, y la Sección 3.2 muestra que no lo es: el término de política r_p es revocable y el de norma r_n no. El índice no distingue entre los dos, de modo que dos organizaciones con el mismo IDA pueden retener horas humanas de durabilidad muy distinta, y la que se apoya en política está expuesta a un riesgo que este trabajo no cuantifica: el de su propia decisión futura. La partición se informa al lado del índice y no dentro de él, por la misma razón que el margen de continuidad — incorporarla exigiría una probabilidad de revocación que nadie puede estimar hoy sin inventarla. Reconocer el límite y exponer el dato es todo lo que corresponde afirmar acá.

El respaldo externo no se puede contar dos veces. R se declara para un área, y el modelo lo trata como si estuviera disponible para ese piso. Cuando una misma organización evalúa varios procesos, las mismas personas suelen figurar como respaldo en más de uno, y ahí los índices dejan de poder leerse juntos: cada proceso informa una exposición reducida por una capacidad que no tiene en exclusiva. El caso peor es además el más probable, porque una caída del proveedor golpea a todos los procesos **a la vez**, que es justamente cuando el respaldo compartido no alcanza para los dos. Mientras el modelo se aplique a un proceso por vez el problema no aparece; al agregar hacia arriba, R debe repartirse entre los procesos que lo invocan y no replicarse en cada uno.

Terminología: La expresión “dependencia de IA” se usa también en la literatura de interacción humano-computadora y de psicología para la dependencia de un usuario individual respecto de un sistema de IA. El presente índice mide algo distinto: la dependencia operativa de una organización respecto de un proveedor externo. Las dos cosas no están relacionadas y no deberían confundirse. El puntaje de descarga cognitiva de Padmakumar y otros [15], que estima la fracción de los pasos de una tarea que un usuario delega en una herramienta construyendo un flujo de trabajo contrafáctico, es la medida a nivel individual. Es conceptualmente el análogo a nivel de tarea de a_{ef} aquí, y donde un proceso sea observable podría servir de instrumento para estimar a y η en lugar de elicitarlos.

7. Conclusión

Las organizaciones que dependían de esos dos modelos sin una contingencia ensayada enfrentaron en junio de 2026 una interrupción abrupta de casi tres semanas, sin que fallara ninguna infraestructura, y la capacidad que les quedó dependió de los respaldos que hubieran conservado, incluida la capacidad humana. Descubrieron, en el peor momento posible, un número que nunca habían calculado. Este trabajo propone que ese número se calcule de antemano, con datos que la organización ya tiene, y se informe junto al ahorro en lugar de en su reemplazo.

El modelo reencuadra el factor humano: deja de ser un valor declarado de la organización y pasa a ser infraestructura de continuidad medible, y le da a quien decide una única cifra defendible para llevar a una negociación con un proveedor. Su afirmación principal es modesta y verificable: que pasado un piso que la propia organización declara, automatizar más deja de comprar ahorro y sigue comprando exposición, y que ambos comportamientos se siguen de las ecuaciones y no del relato. La Sección 4.5 establece que esa afirmación, y el orden de configuraciones que inducen las primas a gasto de IA fijo, sobreviven a una perturbación del ±50 por ciento de todos los coeficientes de riesgo del modelo; los veredictos sobre un proyecto concreto no, y por eso se informan como umbral.

El modelo se ofrece como un marco cuantitativo propuesto, no como un índice validado. Sus coeficientes esperan calibración y sus predicciones esperan casos empíricos. Tanto la implementación como la batería de pruebas son públicas precisamente para que la refutación, si llega, pueda ser específica.

Los recargos de arquitectura de la Tabla 5 y el descuento por respaldo son las primeras cantidades que deberían cambiar. Quienes corran el modelo sobre su propia operación, y las organizaciones que puedan aportar datos anónimos de incidentes, quedan invitados a escribir al autor: calibrar esos valores contra casos observados es lo que llevaría al IDA de marco propuesto a marco validado.

La dirección de la regulación es compatible con el problema que se aborda acá, aunque no es evidencia a favor del método propuesto para abordarlo. Un comité parlamentario ya recomendó designar a los grandes proveedores de IA como terceros críticos [12], y una dependencia designada es una a la que se le puede exigir una contingencia dimensionada en lugar de una intención documentada.

6.1 Dos consecuencias para quien decide

El horizonte de recupero no es neutral. T_{max} entra al modelo como una política de la organización, y el modelo no opina sobre su valor. Conviene sin embargo señalar lo que el propio objeto de estudio le hace a ese parámetro: la tecnología que se está comprando cambia de precio y de capacidad en plazos cortos, de modo que un proyecto que necesita dieciocho o veinticuatro meses para pagarse está calculando el recupero de una configuración que probablemente ya no sea la vigente cuando termine de pagarse. El caso de referencia es exactamente ese: el proyecto se recupera en veinte meses y por eso no pasa. No es una regla del modelo, pero sí una lectura defendible de sus resultados: **cuanto más rápido se mueve la capa que se contrata, más corto debería ser el T_{max} con el que se la evalúa.**

Cuándo conviene traer la IA adentro. La misma aritmética contesta una pregunta que los directorios hacen seguido. Correr los modelos en infraestructura propia tiene costo fijo y multiplicador bajo; usar una API tiene costo variable y multiplicador alto. Lo propio conviene cuando $\lambda_{propia} \cdot C_{propia} < \lambda_{api} \cdot c \cdot H \cdot a_{ef}$, es decir cuando el volumen automatizado es suficiente para que el costo variable supere al fijo.

Despejando, el umbral queda en $H \cdot a_{ef} = \lambda_{propia} \cdot C_{propia} / (\lambda_{api} \cdot c)$. Lo que decide, entonces, no es el fierro sino **el precio de la hora de API**, porque el umbral es inversamente proporcional a c. Con el equipamiento del caso —8.420 por mes, $\lambda = 1{,}02$ contra multi-nube con plan en 1,10— y $c = 2$, el umbral está en **3.904 horas de IA por mes**: unas 24 personas dedicadas a tiempo completo, o unas 64 del área en la configuración de referencia, donde solo el 38,4 por ciento de las horas está automatizado. Con un modelo de precio bajo, del orden de 0,20 por hora, el mismo equipamiento necesita diez veces más volumen para justificarse.

La lectura práctica es la misma en los dos extremos. Con las diez personas del caso la API imputa 1.352 por mes contra 8.588 de infraestructura propia, y la diferencia es tan grande que ninguna elección de primas la da vuelta. **Para la enorme mayoría de las áreas, traer la IA adentro no se justifica por costo, y la respuesta**

correcta al riesgo no es mudarse sino repartirse: multi-nube con una contingencia ensayada. La infraestructura propia empieza a pagarse recién a escala, o cuando el dato no puede salir de la organización — que es una razón legal y no económica, y el modelo no la arbitra.

Uso de herramientas de inteligencia artificial

El autor declara haber usado asistentes de inteligencia artificial — Claude, de Anthropic — a lo largo de este trabajo: para discutir la formulación del modelo, revisar su consistencia interna, implementar y verificar la calculadora de referencia y la batería de casos de borde, y redactar y corregir partes del manuscrito. Las decisiones de modelado, la elección de los coeficientes, la interpretación de los resultados y la redacción final son del autor, que responde por el contenido en su totalidad. Esta declaración se incluye porque varias sedes de publicación la exigen y porque el objeto de este trabajo hace que omitirla sería incoherente.

Las herramientas usadas no figuran como autoras. La autoría supone responder por el trabajo ante quien lo lea, lo critique o lo cite, y un sistema de IA no puede asumir esa responsabilidad.

Disponibilidad

Modelo interactivo: https://modelo-ida.web.app · **Edición en inglés:** https://modelo-ida.web.app/en
Código fuente y batería de pruebas: https://github.com/All-Aideas/Modelo-IDA
Archivo: https://doi.org/10.5281/zenodo.22070415 — DOI de concepto, resuelve siempre a la última versión depositada
Licencia: MIT. Sin registro, sin servidor, ningún dato sale del navegador.

Referencias

[1] Shelby, J. (2026). *The AI Resilience Gap: Bringing Artificial Intelligence Inside the Operational Resilience Perimeter.* arXiv:2607.07359.

[2] Riat, C. (2026). *Modelo IDA — Índice de Dependencia de IA* (v1.0.0). All AIdeas SAS. https://doi.org/10.5281/zenodo.22070415

[3] ISO/IEC 42001:2023. *Information technology — Artificial intelligence — Management system.* International Organization for Standardization.

[4] ISO 22301:2019. *Seguridad y resiliencia — Sistemas de gestión de la continuidad del negocio — Requisitos.* Organización Internacional de Normalización.

[5] Reglamento (UE) 2022/2554 sobre la resiliencia operativa digital del sector financiero (DORA). Diario Oficial de la Unión Europea.

[6] Anthropic (2026). *Statement on the US government directive to suspend access to Fable 5 and Mythos 5.* 12 de junio de 2026. https://www.anthropic.com/news/fable-mythos-access

[7] Al Jazeera (2026). *US orders Anthropic to disable AI models for all foreign nationals.* 13 de junio de 2026. https://www.aljazeera.com/news/2026/6/13/us-orders-anthropic-to-disable-ai-models-for-all-foreign-nationals

[8] CNBC (2026). *Anthropic says Trump admin has lifted export controls on Claude Fable 5 and Mythos 5.* 30 de junio de 2026. https://www.cnbc.com/2026/06/30/anthropic-says-trump-admin-has-lifted-export-controls-on-claude-fable-5-and-mythos-5.html

[9] Bank of England y Financial Conduct Authority (2024). *Artificial intelligence in UK financial services — 2024.* 21 de noviembre de 2024. https://www.bankofengland.co.uk/report/2024/artificial-intelligence-in-uk-financial-services-2024

[10] Bank of England, Financial Policy Committee (2025). *Financial Stability in Focus: Artificial intelligence in the financial system.* 9 de abril de 2025. https://www.bankofengland.co.uk/financial-stability-in-focus/2025/april-2025

[11] Bank of England, Prudential Regulation Authority y Financial Conduct Authority (2024). *Operational resilience: Critical third parties to the UK financial sector.* Supervisory Statement SS6/24, noviembre de 2024.

[12] House of Commons Treasury Committee (2026). *AI in Financial Services.* Fifteenth Report of Session 2024–26, HC 684, 20 de enero de 2026.

[13] Barr, D. (2026). *The AI Transformation Gap Index (AITG): An Empirical Framework for Measuring AI Transformation Opportunity, Disruption Risk, and Value Creation at the Industry and Firm Level.* arXiv:2603.13278 [econ.GN], 27 de febrero de 2026.

[14] Falk, B. H. y Tsoukalas, G. (2026). *The AI Layoff Trap.* arXiv:2603.20617 [econ.TH], 21 de marzo de 2026, revisado el 3 de junio de 2026.

[15] Padmakumar, V., Ibrahim, L., Wang, Z. Z., Wang, J., Liao, Q. V. y Yang, D. (2026). *Offloading Score: Measuring AI Reliance Through Counterfactual Workflows.* arXiv:2605.29392 [cs.SE], 28 de mayo de 2026.